

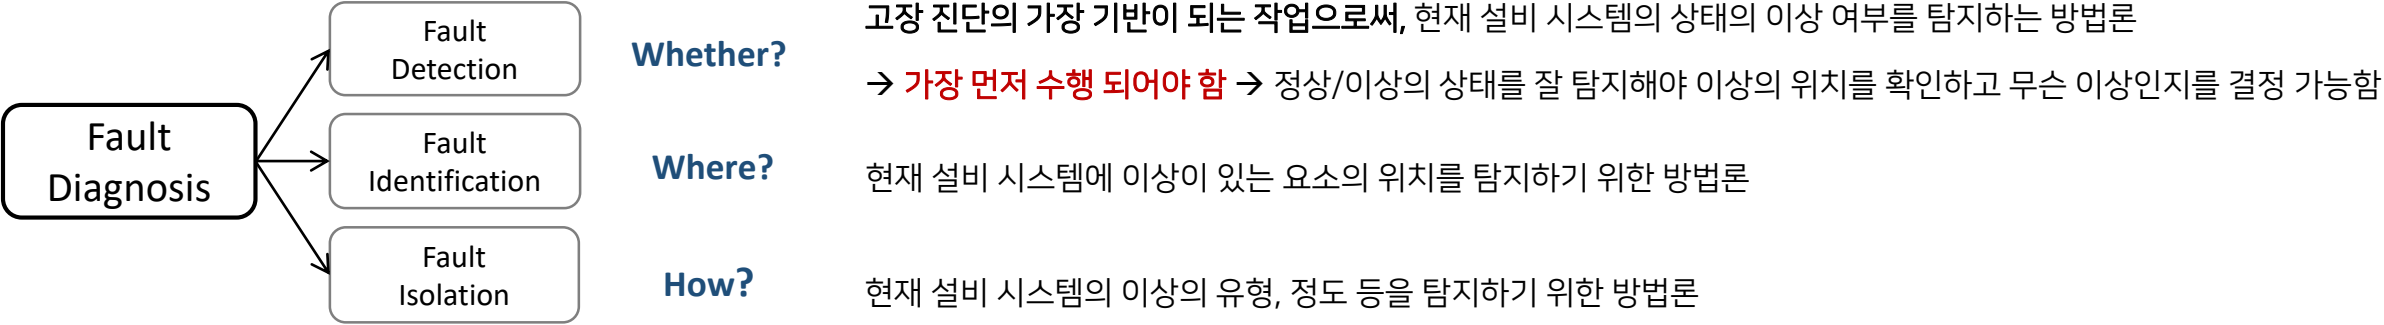
Convolutional Auto Encoder based Feature Extraction for Bearing Fault Detection

팀 원 이호연
윤도식
임동현

1. Introduction – Fault Diagnosis/Detection

❖ Fault Diagnosis (고장 진단)

- 고장 진단이란 부품 혹은 설비 시스템의 상태 정보를 토대로 시스템을 진단하는 방법
 - 고장 진단은 "Fault Detection", "Fault Isolation", "Fault Identification"으로 분류함¹⁾



❖ Fault Detection (이상 탐지)


- 고장 탐지는 설비 시스템의 예기치 못한 이상 상태를 탐지하는 방법론으로, 정상 데이터 학습하여 현재 시스템의 정상/이상 상태를 탐지하는 방법론
 - 실제 설비 시스템 정상 상태의 가동 비율이 매우 높기 때문에 이상의 데이터 수집이 어려움 → 정상 상태의 데이터만을 사용하는 비지도학습 기반의 이상치 탐지 모델을 구축함
- 시스템의 상태를 조기에 탐지함으로써 사전 조치를 통해 시스템 운영의 효율성을 최대화 할 수 있음
 - 이상 탐지를 통해 시스템의 유휴 시간 최소화, 관리자에게 유용한 알림, 인명피해 방지, 비용 감소 등의 효과를 얻을 수 있음

¹⁾Z. Gao, C. Cecati and S. X. Ding, "A Survey of Fault Diagnosis and Fault-Tolerant Techniques—Part I: Fault Diagnosis With Model-Based and Signal-Based Approaches," in IEEE Transactions on Industrial Electronics, vol. 62, no. 6, pp. 3757-3767, June 2015

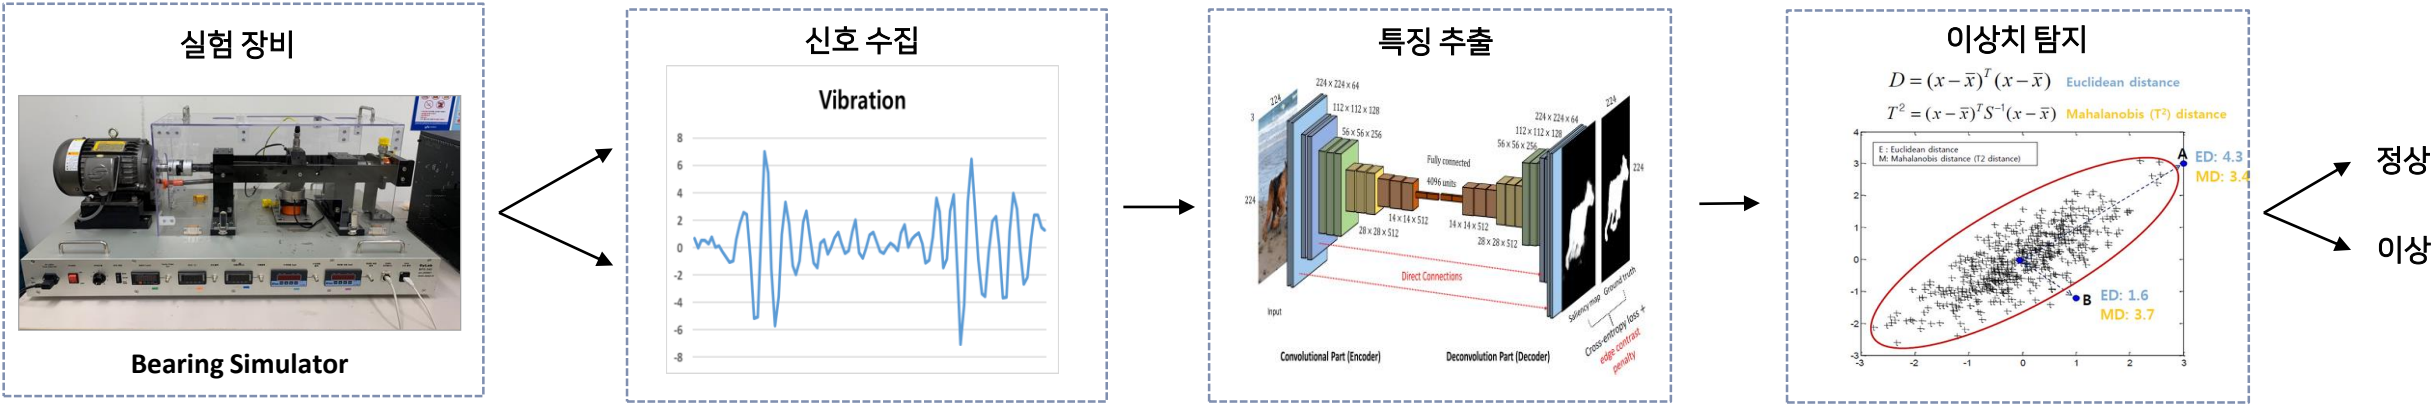
1. Introduction – Signal-Based Fault Detection

❖ 센서 신호 데이터

- 설비 시스템의 상태 판단의 정확성과 신뢰성을 높이기 위해 센서들을 통해 수집되는 신호 데이터를 활용함
- 설비 시스템의 구성 요소 중 하나인 베어링은 설비 시스템 고장을 유발하는 가장 큰 원인 중 하나로서 약 41%를 차지함 ¹⁾
 - 베어링을 통한 이상 탐지는 Vibration, Acoustic, electric 센서의 신호 데이터를 활용함 ^{2) 3)}
 - 베어링을 통해 수집되는 신호 데이터는 기계/시스템의 가동 상태 정보를 직관적으로 내포하고 있음



- 신호 데이터는 추상성이 높은 (Highly abstract) 데이터로 개별적인 값은 의미가 없음
- 효과적인 신호 데이터 분석을 위해서 특징을 추출하는 것은 매우 중요함



¹⁾"Report of Large Motor Reliability Survey of Industrial and Commercial Installations, Part I," in IEEE Transactions on Industry Applications, vol. IA-21, no. 4, pp. 853-864, July 1985


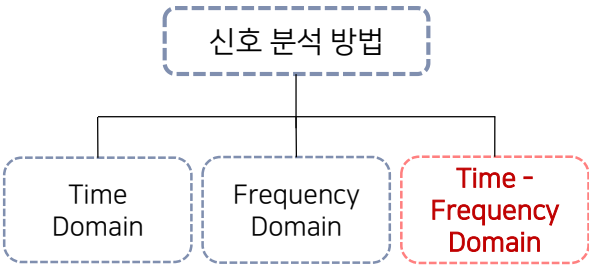
²⁾Temperature dependent friction estimation: application to lubricant health monitoring, Marton & Linden 2012

³⁾Acoustic condition monitoring of wind turbines: tip faults ,Fazenda & Comboni 2012

2. Related Works – Signal Processing & Feature Engineering

❖ 신호 처리 및 특징 추출

- 기존 연구에서는 다양한 센서에서 수집된 신호 데이터를 분석하여 기계 설비의 이상 탐지를 수행함→진동 신호 데이터를 주로 사용함
- 신호 데이터 기반의 이상치 탐지 기술은 시간, 주파수, 시간-주파수 관점으로 수행됨
- 시간 관점에서의 신호 데이터 기반의 설비 시스템의 이상 탐지는 신호의 통계적 특성 (특정 구간 내의 첨도, 왜도, 최댓값 등) 을 사용하여 분석을 수행함
- 주파수 관점에서의 신호 데이터 기반의 설비 시스템의 이상 탐지는 시간 관점의 신호 데이터를 푸리에 변환법, 웨이블릿 변환법 등을 통해 주파수의 대역으로 변환하여 주파수의 진폭 및 스펙트럼을 통해 분석을 수행함



❖ 한계점


- 통계적 방법론들은 지역적인 진폭의 특정한 주파수와 연관이 있기 때문에 베어링 데이터의 전체의 정보를 제공 할 수는 없다. ¹⁾
- 시간 관점과 주파수 관점은 둘 모두를 함께 고려하지 않는다면 이상치를 탐지하는 효과가 떨어진다. ¹⁾

본 연구에서는 시간-주파수 관점 분석 방법을 사용하여, 신호 데이터의 특징을 추출함

¹⁾ Wavelet transform with spectral post-processing for enhanced feature extraction, Wang & Gao, 2002

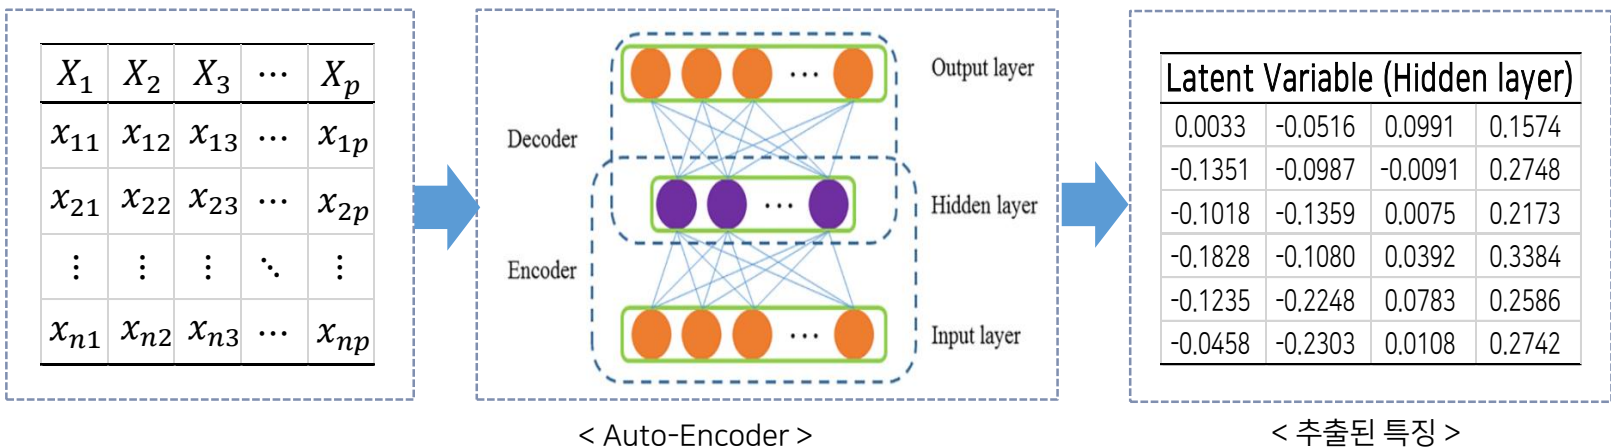
2. Related Works – PCA, Stacked Auto-Encoder

❖ Principle Component Analysis (PCA)- 주성분 분석



- PCA는 고차원의 데이터를 저차원의 데이터로 변환시키는 대표적인 차원 축소 기법
- 데이터의 변수간의 선형 상관관계를 반영하여 원본데이터의 분산을 잘 보존하는 방향으로 작동함
- 주파수 분석을 적용한 신호 데이터에 PCA를 활용하는 기존 연구가 존재함¹⁾
- **주성분 분석은 데이터의 변수간의 비선형적 관계를 반영하지 못함**

❖ Auto-Encoder - 오토인코더



- 오토 인코더는 대표적인 비지도 학습 기반의 모델로 크게 인코더와 디코더의 구조로 나눌 수 있음
- 오토 인코더를 통해 인풋 데이터가 입력되어 복원된 데이터와의 복원 오차가 충분히 작다면 Hidden layer는 인풋데이터의 특징이 잘 반영된 것으로 고려할 수 있음²⁾
- **오토인코더는 추상성이 높은 데이터의 특징을 잘 추출 하지 못함**

본 연구에서는 추상성이 높은 데이터의 비선형적 관계를 반영하여 특징을 추출 가능한 합성곱 오토인코더를 사용함


¹⁾Englehart, K., Hudgins, B., Parker, P. A., & Stevenson, M. (1999). Classification of the myoelectric signal using time-frequency based representations. *Medical engineering & physics*, 21(6-7), 431-438

²⁾ A Novel Bearing Health Indicator Construction Method Based on Ensemble Stacked Autoencoder. Pengfei & Jizhong 2019

2. Related Works – Outlier Detection


❖ 이상치 탐지

- 관리도는 다양한 설비 시스템의 작동 상태를 진단하기 위해 광범위하게 사용되는 방법론임
 - 관리도의 구성 요소는 설비의 작동 상태를 표현하는 관리통계량과 작동 상태의 이상여부를 판정하는 기준이 되는 관리 한계선의 두가지 요소로 구성됨 ¹⁾
- 기존 연구에서는 설비 시스템의 비정상적인 상태의 신속한 탐지를 위해 관리도를 사용하였으며, 크게 두가지 단계 설비 시스템을 관리함 ²⁾
 - Phase 1 : 정상적인 설비 작동 상태의 관리 통계량을 통해 관리 한계선을 도출하는 단계
 - Phase 2 : Phase 1에서 도출된 관리 한계선을 통해 설비 시스템이 정상 / 이상 여부를 모니터링하는 단계
- 관리도는 단변량 관리도와 다변량 관리도로 분류되며, 단변량 관리도는 변수 하나에 대해서 관리를 하기 때문에 변수간의 상관성을 반영하지 못한다는 한계점이 존재함 ³⁾



❖ 다변량 관리도 – Hotelling's T² 관리도

- 본 연구에서는 추출된 신호 특징들간 상관성을 반영하기 위해 가장 널리 활용되는 Hotelling's T² 관리도를 적용함 ⁴⁾
- 관리 통계량 : $T^2 = (X - \bar{X})^T S^{-1} (X - \bar{X})$, 관리 한계선 : $CL_{T^2} = \frac{p(n+1)(n-1)}{n(n-p)} \sim F(\alpha, p, n-p)$
- 기존의 Hotelling's T² 관리도에서 정의된 관리한계선은 데이터가 정규분포를 따른다는 가정이 성립 해야함



데이터가 정규 분포가 아닌 다른 분포를 따른다면 **거짓 경보(false alarm)가 증가하는 문제가 발생함**

¹⁾Introduction to Statistical Quality Control, Wiley, Hoboken, 2021

²⁾A Multivariate Robust Control Chart for Individual Observations, Chenouri & Steriner, 2009





³⁾Multivariate statistical process control and signature analysis using eigenfactor detection methods, Chen et al. 2001

⁴⁾Multivariate Statistical Analysis for Network Attacks Detection, Hariri & Yousif. 2005

3. Proposed Framework - ① Time-Frequency Spectrogram

❖ Spectrogram

- Spectrogram은 시간에 따른 주파수의 정보를 나타내는 방법으로 시간과 주파수의 강도 정보를 동시에 반영한다.¹⁾
- Spectrogram은 시간 축(x-axis)과 주파수(y-axis) 축에 특정 주파수의 강도를 나타내는 2차원 형태로 이미지의 형태로 표현될 수 있다.
- Short-time Fourier transform을 사용해 신호 데이터를 spectrogram 데이터로 변환함



hanning window

$$w(n) = 0.5 - 0.5 \cos\left(\frac{2\pi n}{M-1}\right) \quad 0 \leq n \leq M-1$$

window_size:260,
overlap_size:182,
spectrogram shape: 128x128,
window function: hanning window²⁾


¹⁾ Cohen, Leon. *Time-frequency analysis*. Vol. 778. Prentice hall, 1995.

²⁾ Blackman, R. B., & Tukey, J. W. (1958). The measurement of power spectra from the point of view of communications engineering—Part I. *Bell System Technical Journal*, 37(1), 185-282.

3. Proposed Framework - ② Convolutional Autoencoder

❖ 합성곱 오토인코더 (CNN+AE)

- 대표적인 특징 추출 기법인 합성곱 신경망과 차원 축소 기법인 오토인코더를 결합한 방법론

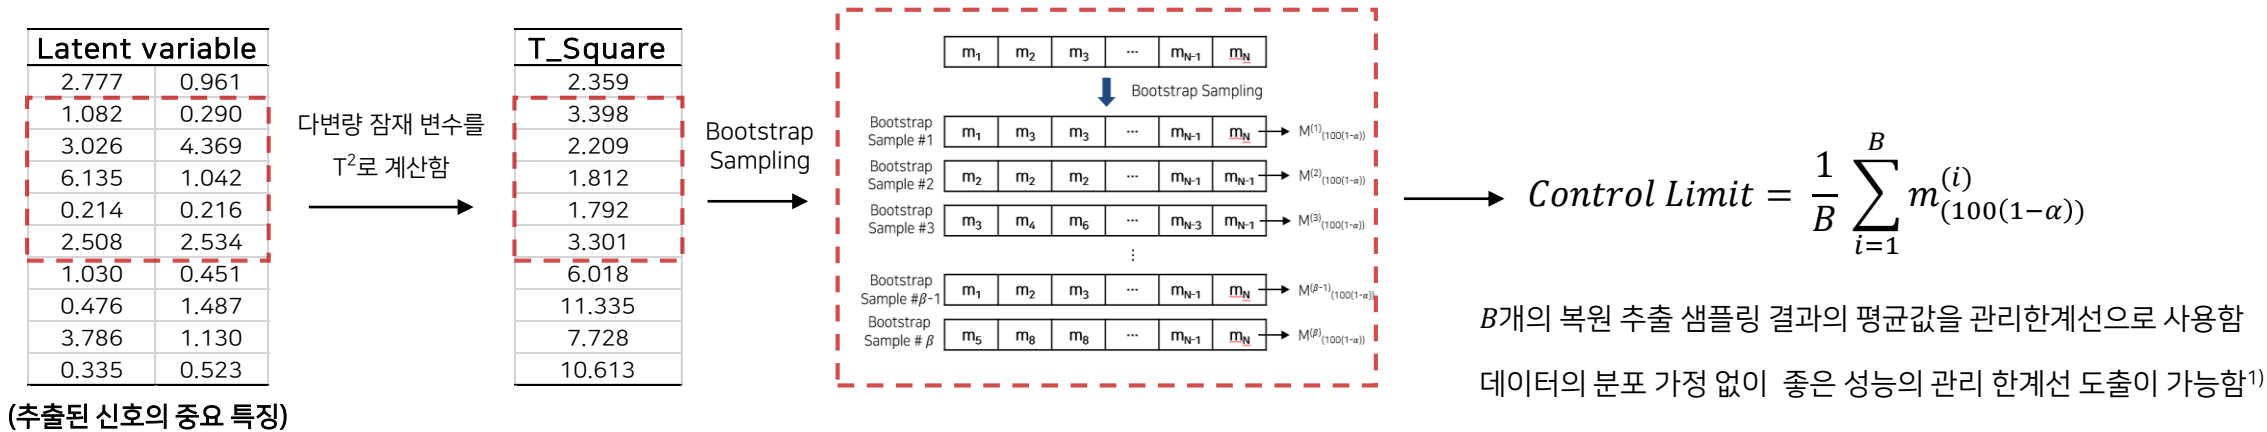


- 비정형 데이터의 특징을 추출하는데 효과적인 방법론인 CNN과 비지도 학습 기반의 특징 추출 기법인 오토 인코더를 결합한 방법론임
- Encoder를 통해 인풋 데이터의 특징이 잠재 변수로 요약이 되며, 잠재 변수를 Decoder를 통해 인풋 데이터로 복원하는 구조임
- Encoder의 인풋데이터와 Decoder의 복원 데이터의 복원 오차가 작다면 잠재 변수는 특징이 잘 요약된 변수임
- 잠재 변수를 센서 신호의 중요 특징으로 간주하여, 이에 대해 다변량 관리도를 적용한 이상치 탐지 모델을 제시하고자 함

3. Proposed Framework - ③ Multivariate Control Chart

❖ Bootstrap T² 관리도

- 본 연구에서는 데이터의 분포 가정이 필요 없는 **비모수 기반의 통계적 추론 기법 중 하나인 기법인 Bootstrap 기법을 활용하여 관리 한계선을 도출함**
 - CAE를 통해 추출된 잠재 변수를 이용하여 Hotelling's T² 통계량을 계산 후, 이에 대해 Bootstrap 기법을 적용하여 관리한계선을 도출함



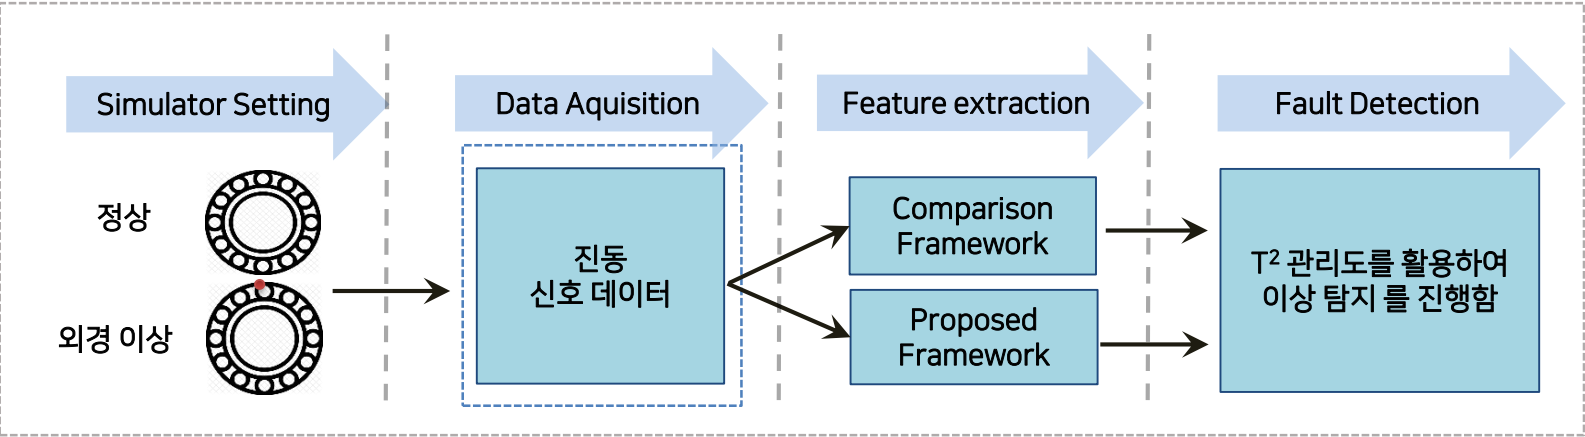
❖ 평가 지표

- α (Type 1 error)** : 설비 시스템이 정상 상태 (통제 불가능한 요인)임에도 이상 상태 (통제 가능한 요인) 로 판단하는 오류
 - 설비 시스템의 정상 상태에서 발생하는 거짓 경보로 실제 설비 시스템에서는 제 1종 오류에 민감함 → 설비 시스템의 가동 비율이 정상 상태가 이상 상태에 비해 매우 많기 때문임
- β (Type 2 error)** : 설비 시스템이 이상 상태 (통제 가능한 요인) 임에도 불구하고 정상 상태 (통제 불가능한 요인)로 판단하는 오류
 - 설비 시스템의 이상 상태에서 발생하는 제 2종 오류 → 실제 설비 시스템의 가동 비율이 이상 상태가 정상 상태에 비해 빈도수가 매우 적음

¹⁾ Bootstrap-Based T² Multivariate Control Charts, Phaladiganon et al. 2011
²⁾ False alarm classification for multivariate manufacturing processes of thin film transistor-liquid crystal displays, Kang & Kim 2015

4. Experiment – Overall Process/Experiment Condition

❖ Overall Process of experiment




Comparative Method

Experiment	Method
1	Time-Domain 1-D CAE
2	Frequency-Domain 1-D CAE
3	Time-Frequency-Domain Statistical
4	Time-Frequency-Domain PCA
5	Time-Frequency-Domain Vibration 2-D CAE (Proposed Method)

❖ 실험 조건 (베어링 시뮬레이터)

실험 조건	사용한 신호 Vibration(진동)	회전 속도 1200	고장의 강도 약	사용한 베어링 종류 정상, 외경 이상
-------	-------------------------	---------------	-------------	-------------------------

- 각 실험 별 설정한 실험 조건을 고정하여 실험을 진행함
 - 실험 별 1초당 10,240개(10,240Hz)의 데이터를 수집하며, 5분의 실험을 반복적으로 수행함
 - 역동적인 신호인 진동 신호를 수집함
 - 정상 베어링 데이터는 학습 데이터와 평가 데이터로 나누어 사용함
 - 외경 이상 베어링은 다른 이상 베어링에 비해 회전축의 영향을 적게 받아 외경 이상 베어링을 우선적으로 실험에 사용함¹⁾



- | | |
|------------------|---------------------|
| 0. Motor | 5. Amplifier |
| 1. Coupling | 6. Vibration Sensor |
| 2. Shaft | 7. Horizontal load |
| 3. 베어링 | 8. Pressure pump |
| 4. Vertical load | |

¹⁾ FaultFace Deep Convolutional Generative Adversarial Network(DCGAN) based Ball-Bearing failure detection method, Viola et al. 2020

5. Result

❖ 관리도 결과 (Expected $\alpha = 0.05$)

Phase 2
Test 데이터 사용

Test Normal


CAE
(Time domain only)

CAE
(Frequency domain only)

통계 기반 특징 추출
(Time- Frequency)

PCA
(Time-Frequency)

CAE
(Time-Frequency)
Proposed



Test Out


CAE
(Time domain only)

CAE
(Frequency domain only)

통계 기반 특징 추출
(Time- Frequency)

PCA
(Time-Frequency)

CAE
(Time-Frequency)
Proposed



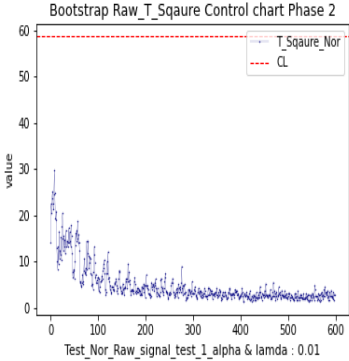
5. Result

❖ 관리도 결과 (Expected $\alpha = 0.01$)


Phase 2
Test 데이터 사용

Test Normal


CAE
(Time domain only)



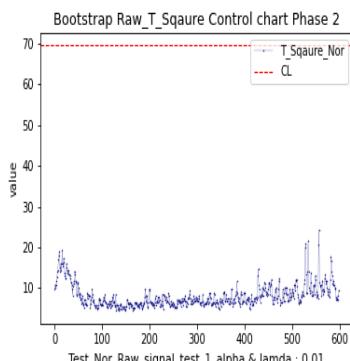
CAE
(Frequency domain only)



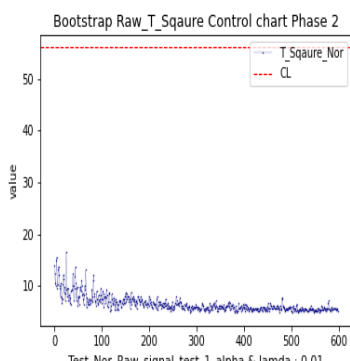
통계 기반 특징 추출
(Time- Frequency)



PCA
(Time-Frequency)




CAE
(Time-Frequency)
Proposed




Test Out


CAE
(Time domain only)




CAE
(Frequency domain only)




통계 기반 특징 추출
(Time- Frequency)



PCA
(Time-Frequency)



CAE
(Time-Frequency)
Proposed



5. Result

❖ 베어링 신호 이상 탐지 실험 결과

Table 1) 제 1종 오류 α

Bootstrap T Square	Phase 2 to Nor				
Expected α	통계 기반 특징 추출 (Time- Frequency)	PCA (Time-Frequency)	CAE (Time domain only)	CAE (Frequency domain only)	CAE (Time-Frequency) Proposed
0.05	0.1122	0.0387	0.0003	0.0781	0.0013
0.01	0.0147	0.0267	0	0.016	0

Table 2) 제 2종 오류 β

Bootstrap T Square	Phase 2 to Out				
β	통계 기반 특징 추출 (Time- Frequency)	PCA (Time-Frequency)	CAE (Time domain only)	CAE (Frequency domain only)	CAE (Time-Frequency) Proposed
Expected $\alpha = 0.05$	0	0	0.8534	0.2294	0
Expected $\alpha = 0.01$	0	0	0.9199	0.594	0

- 두 가지 Expected α 에서 모두 “Time 1-D CAE”의 1종 오류가 제일 낮은 값을 보였으나 2종 오류가 다른 방법보다 월등히 높은 값을 보였음
- “Frequency 1-D CAE”는 1,2종 오류 모두 다른 방법론에 비해 좋은 성능을 보이지 못함
- “Time-Frequency Stat”와 “Time-Frequency PCA”는 2종 오류가 모두 0으로 매우 낮았지만,
- Expected $\alpha = 0.05$ 에서 1종 오류의 값이 각각 0.1122, 0.0387로 낮지 않은 수치를 가짐
- “Time-Frequency Vibration 2-D CAE”는 1,2종 오류 모두 0이거나 0에 매우 가까워, 전체 실험 비교군 중에서 가장 뛰어난 성능을 보임

6. Conclusion

Introduction

- 본 연구는 추상성이 높은 신호 데이터의 특징을 추출하여 설비 시스템의 정상/이상 상태를 진단 하기 위해 합성곱 오토인코더와 Bootstrap 기반의 Framework를 제시함

Highlights

- 시간에 따른 주파수 영역의 강도의 변화를 나타내는 Time-Frequency Spectrogram을 활용하여 신호 데이터를 전처리함
- 비정형 데이터의 특징 추출에 효과적인 CNN과 비지도학습 기반의 차원 축소 기법인 Auto Encoder를 결합하여 신호 데이터의 특징을 추출하고자 함

Results

- Time-Frequency 2D 기법을 활용한 기법들은 모두 제 2종 오류가 0으로 매우 낮은 값을 보임과 동시에 1D 기법들에 비해 낮은 제 1종 오류를 갖는 것으로 보아 Time-Frequency 관점에서 신호 데이터를 처리하는 것이 특징 추출에 더욱 효과적이라고 볼 수 있음
- Time 1-D CAE와 Time-Frequency 2-D CAE는 제 1종 오류에 대해서는 큰 차이가 없었지만 제 2종 오류는 2-D CAE의 성능이 월등히 높았던 것으로 보아 제안한 Time-Frequency 2D CAE가 신호 데이터로부터 이상 상태 탐지에 효과적인 특징 추출에 뛰어나다고 볼 수 있음